

**Zadání II. seminární práce z předmětu
Počítačové zpracování signálu (KI/PZS)**

Klasifikace zvukových záznamů

ZS 2024/25

Meloshyn Serhii
Osobní číslo: st99554
f22638

Zadání

Ve zdrojové databázi VOICED (PhysioNet) se nachází 208 hlasových záznamů písmene „a“ (58 zdravých, 150 patologických). Cílem je načíst záznamy, provést analýzu v časové a frekvenční oblasti (včetně FFT a keprální analýzy) a klasifikovat úseky nejprve na zdravé vs. patologické a následně u patologických rozlišit jednotlivé poruchy (hyperkinetic dysphonia, hypokinetic dysphonia, reflux laryngitis). Úspěšnost postupu je porovnávána s anotacemi (diagnózami) v hlavičkových souborech.

Postup řešení

1. Načtení a předzpracování dat

Záznamy jsou načteny pomocí knihovny wfdb (pouze pro načtení dat). Pro každý záznam se načte signál `p_signal` a vzorkovací frekvence `fs`. Diagnóza je extrahována z hlavičkového souboru (`.hea`) ze řádku obsahujícího „Diagnosis:“.

2. Výběr reprezentativních záznamů

Pro demonstraci jsou automaticky vybrány čtyři záznamy: jeden zdravý a tři patologické (každý pro jednu poruchu). V konzoli je vypsan seznam vybraných záznamů a jejich diagnóz.

3. Analýza v časové oblasti

Pro každý vybraný záznam je vykreslen časový průběh (např. prvních 3 s). Vizualizace umožňuje porovnat průběh zdravého a patologických hlasů.


4. Frekvenční analýza (FFT)

Je provedena rychlá Fourierova transformace (FFT) a vykresleno amplitudové spektrum v kladných frekvencích. Spektra ukazují rozdíly v harmonické struktuře a rozložení energie mezi diagnózami.


5. Kepstrální analýza

Kepstrum je získáno jako $\text{IFFT}(\log(|\text{FFT}|))$. Z kepra lze sledovat pravidelnost a periodičnost signálu (např. výraznost keprálního vrcholu).


Výsledky




Obrázek 1: Časové průběhy (healthy, hyperkinetic, reflux, hypokinetic)



Obrázek 2: Časové průběhy – detail / porovnání úseků



Obrázek 3: Amplitudová spektra (FFT) vybraných záznamů



Obrázek 4: Kepstra vybraných záznamů

Statistika úspěšnosti klasifikace úseků

Podle zadání musí protokol obsahovat tabulku (resp. statistiku) úspěšnosti klasifikace na zdravé vs. patologické a následně na jednotlivé patologie. Níže jsou uvedeny výsledky vyhodnocení na úrovni segmentů (úseků) získané z implementované pipeline.

Krok 1: Healthy vs. Pathological

Počet segmentů: 99

Přesnost (accuracy): 0.808

Krok 2: Typ patologie (3 třídy)

Počet patologických segmentů: 90

Přesnost (accuracy): 0.456

Třída	Precision	Recall	F1-score (support)
hyperkinetic	0.51	0.62	0.56 (45)
hypokinetic	0.18	0.15	0.16 (27)
reflux	0.69	0.50	0.58 (18)
macro avg	0.46	0.42	0.43 (90)
weighted avg	0.45	0.46	0.45 (90)

Celková accuracy pro tento krok: 0.46 (na 90 patologických segmentech).

healthy + 3 patologie (4 třídy)

Všechny segmenty: 99

Přesnost (accuracy): 0.364

Třída	Precision	Recall	F1-score (support)
healthy	0.00	0.00	0.00 (9)
hyperkinetic	0.51	0.56	0.53 (45)
hypokinetic	0.20	0.15	0.17 (27)
reflux	0.35	0.39	0.37 (18)
macro avg	0.27	0.27	0.27 (99)
weighted avg	0.35	0.36	0.36 (99)

Celková accuracy pro 4 třídy: 0.36 (na 99 segmentech).

Slovní zhodnocení a závěr

V prvním kroku (healthy vs. pathological) dosahuje metoda na úrovni segmentů accuracy 0.808, což ukazuje, že zvolené příznaky dokážou poměrně spolehlivě oddělit zdravý hlas od patologií. Ve druhém kroku (3 typy patologie) je accuracy 0.456 – rozlišení konkrétní poruchy je výrazně

náročnější, zejména pro hypokinetickou dysfonii (nižší precision/recall). V celkové 4-třídní klasifikaci je accuracy 0.364. Pro zlepšení lze doplnit robustnější příznaky (např. MFCC, jitter/shimmer), lepší segmentaci a vyvážení tříd.

Použitá literatura a zdroje

PhysioNet – VOICED Database (<https://physionet.org/content/voiced/1.0.0/>).

WFDB Python package – načtení záznamů.